个人信息

姓名 梅某 | 手机号 189****1714 | 邮箱 189****@163.com

目标职位：大模型应用开发工程师 | 学历：本科 | 工作年限：4 年 | 到岗时间：一个月内

个人优势

1．**业务拆解**：能把数据编排、工单诊断这类“模型给建议、人来确认、系统去执行”的流程拆成校验、审批、执行与回执节点，明确模型与人工的分工边界，用审批绑定版本、幂等键和执行租约保证确认内容与最终执行一致。

2．**工程闭环**：4 年研发经验，从 Java 后端转向 Python AI 应用，能独立完成 DSL 校验、检索链路、LangGraph 工作流、状态管理到容器化部署与监控的全链路，并跟进上线后的使用反馈。

3．**评测驱动**：每个项目先建评测集（人工编排对照集、150 条诊断保留集、300 条问答 / 微调评测集），把 Bad Case 归因到切分、召回、提示词或规则后逐轮迭代，并将人工修改回流为 few-shot 与训练数据。

专业技能

• 大模型应用能力

1．LangChain / LangGraph：能基于 StateGraph 设计条件路由、多图共享工具层、interrupt 人工中断与恢复，用 checkpointer 持久化长流程；熟悉 Prompt 工程、会话记忆与 Function Calling。

2．RAG：掌握标题感知父子分块、稠密 + BM25 混合召回、RRF 融合与 Reranker 精排、Multi-Query 改写与精确通道路由，能用 Recall@5 / MRR / 忠实度评测集把问题归因到切分、召回或重排环节。

3．Agent 工程化：熟悉“模型生成 → Schema / Pydantic 校验 → 回灌自校正 → 人工审批 → 幂等执行”的闭环模式，以及风险分级、白名单工具、审批绑定版本、执行租约等让模型建议可控落地的手段。

4．上下文与工具：熟悉 MCP / Function Calling 工具封装、按固定顺序与配额组装上下文、多轮历史压缩与前缀缓存；了解 Skills 渐进式加载与 Agent Harness 分层思路。

• 大模型理论储备

1．掌握 Transformer 与注意力机制，理解 RoPE、MHA / MQA / GQA、KV Cache、MoE 的原理及其对推理显存与吞吐的影响，熟悉 BERT、GPT 等预训练架构。

2．掌握神经网络基础（反向传播、权重初始化、激活函数、归一化、残差连接）与机器学习基础方法（分类、回归、特征工程、模型评估）。

• 大模型微调与部署

1．掌握 SFT / DPO 训练流程与 LoRA / QLoRA 原理，能用 LLaMA-Factory + PEFT 完成数据构建、调参消融、评估与通用能力回归；了解 ZeRO 等分布式训练优化原理。

2．掌握 AWQ INT4 量化与 vLLM 部署（前缀缓存、吞吐与 TTFT 压测），具备 HuggingFace / ModelScope 模型获取与私有化部署经验。

• 开发工具与编程语言

1．Python / FastAPI（异步编程、Depends 依赖注入、中间件与生命周期管理、SSE 流式输出）；Java / Spring Boot / Spring AI。

2．MySQL、Redis、PostgreSQL、OceanBase（向量 + 全文索引）、Milvus；Docker / Docker Compose、HAProxy、Prometheus、Linux、Git 与团队协作流程。

3．熟练运用 Claude Code、Codex 等编程工具完成 Workflow 编排及智能体应用开发。

工作经历

数字马力 | AI 大模型开发工程师 | 长沙 | 2024年05月 - 至今

1. 负责 OceanBase 云平台私有化部署场景下的大模型应用研发，覆盖 OCP AI 助手运维知识库 RAG、L1 / L3 分层工单智能诊断 Agent、领域模型微调与私有化推理部署

2. 负责数据接口服务平台智能数据编排引擎的设计与开发：自然语言生成编排 JSON、人工审批、DAG 异步任务调度

武汉东方赛思软件股份有限公司 | Java 应用开发工程师 | 武汉 | 2022年04月 - 2024年03月

1. 根据需求文档，完成技术的设计与编码工作
2. 按时，保质保量完成软件编码工作
3. 完成代码的单元测试，配合相关人员进行系统测试，对软件BUG及时修复

项目经历

项目一：智能数据编排 Agent（2026年05月 - 至今）

项目背景：

数据接口服务平台对内对外提供数据编排能力，原流程需手写编排 JSON 定义节点、依赖与参数，门槛高、易出错、外部客户难以自助。引入大模型将自然语言需求转为可执行编排，经校验、试跑、审批后提交既有 DAG 引擎执行，模型负责理解与生成，平台保证权限、合法性、审批与幂等。

技术栈：Python、FastAPI、LangGraph、LangChain、DeepSeek、Milvus、PostgreSQL、Redis、BGE-M3、BGE-Reranker、MiniLM、SSE、Docker

个人职责：

1. 以既有引擎 JSON 格式反推编排 DSL 的 Schema 与 Pydantic 定义，实现结构、语义（接口存在、类型匹配、权限、无环）、执行约束三层校验，错误定位到节点与字段。
2. 设计接地生成链路：先检索接口目录并经 Function Calling 取得真实定义与样例，再按 DSL 结构化输出；沉淀模板库，先匹配模板再填参数，杜绝编造接口。
3. 实现增量修改与多轮澄清：修改请求走 diff 生成不整份重生，缺失信息追问；校验失败回灌自校正上限 3 轮，仍失败降级人工编辑。
4. 实现试跑预览与审批：样例数据试跑得到字段级输出与版本 diff，高风险编排 interrupt 挂起审批，审批绑定版本、变更即失效、超时提醒。
5. 负责与既有 DAG 引擎集成：幂等键提交、任务状态轮询、超时 UNKNOWN 核对、节点级结果回读；编排版本化、灰度发布与回滚；租户隔离与 Redis 配额。
6. 建立评测与回流：以历史人工 JSON 为对照集，跟踪一次通过率、人工修改比例、执行成功率；校验失败与人工修改 diff 回流为 few-shot 与后续 DSL 小模型训练数据，评估并规划 LoRA + DPO 微调路线。

项目成果：

1. **效率**：编排定义耗时由人工手写约 **180 分钟缩短至 15 分钟**（含生成与审核），**单次耗时下降约 91.7%。**
2. **质量**（历史人工编排 JSON 对照集）：一次通过校验率 68%，人工修改比例 15%，**执行成功率 96%。**

项目二：工单智能诊断 Agent 系统（2025年07月 - 2026年05月）

项目背景：

私有化客户问题由 L1 支持受理、解决不了升级 L3 研发，L1 首响慢、升级多，L3 重复处理相似问题且材料常不全；因不能操作客户系统，处理方式为“看材料、给意见、客户执行、看回执”。构建内部 Agent：L1 阶段给出首答并判定升级，L3 阶段解析客户上传的日志与 OCP 报告做深度诊断、生成分级处理意见，经工程师复核与回执验证闭环。

技术栈：Python、FastAPI、LangGraph、MySQL、Redis、Outbox、OceanBase 向量检索、内部微调模型（统一网关）、SSE、Docker Compose、HAProxy、Prometheus、LangSmith

个人职责：

1. 设计 L1 首答图与 L3 深度图两级 LangGraph 工作流共享工具层，定义置信度不足、客户执行未解决、动作需工程师确认三类升级条件，升级携带已有诊断与材料。
2. 实现客户材料解析：OCP 信息采集 / 巡检 / AWR 报告按章节抽结构化字段，日志按错误模板归并取 Top-N，截图 OCR；材料不足时生成精确到 OCP 操作路径的补充清单。

3. 实现诊断推理：OCP 可疑 SQL 诊断类型、告警项、预案规则沉淀为规则库先行判定；模型做多假设根因分析并按材料逐一验证，按版本匹配已知问题库，Pydantic 结构化输出。
4. 实现处理意见三级风险路由与复核：命令仅从白名单模板填参数，二级以上 interrupt 挂起工程师复核，复核绑定意见版本、变更即失效，幂等下发，回执核对后结案并回流案例。
5. 设计三层状态与四类记忆：业务状态机在服务端、运行状态在 AgentRun / AgentBranch、图内 State 只存过程；执行租约 + 控制版本 + 意见版本防并发；客户环境画像按客户隔离、带版本与有效期。
6. 落地上下文工程与可靠性：上下文按固定顺序与配额组装、分层压缩、超预算前置报错并启用前缀缓存；通知与回写先写入 Outbox 表，由后台任务重试投递，接收端按消息 ID 与意见版本幂等去重，避免重试导致重复生效；Docker Compose 固定版本部署、HAProxy 双副本、Prometheus 告警与复核超时提醒。

项目成果：
1. **离线评测**（150 条固定保留集）：L1 类首答解决率 72%，升级判定准确率 90%，根因命中率 78%，证据引用正确率 95%，违规建议 0。
2. **试运行效果**：L1 首次回复由约 30 分钟缩短至 3 分钟内，升级至 L3 比例下降约 30%；二级以上意见 100% 经复核，重启与接管场景无重复下发。
3. **性能**：工单查询组合索引后 L1 面板 P95 由约 8 ms 降至 5 ms（6 万条工单、并发 4）；检索批处理后 16 并发吞吐约 3 倍；双副本查询吞吐提升约 60%。

项目三：运维领域大模型微调（2025年03月 - 2025年08月）

项目背景：
OCP AI 助手交付客户内网后，不接第三方 API 的客户回退使用内部默认模型，内部工单 Agent 同样以其为底座。通用模型对 OceanBase 参数、错误码、诊断流程回答不准、格式不稳、不确定时易编造。RAG 补知识但不纠正推理习惯，故对 Qwen2.5-7B-Instruct 做 SFT + DPO 领域微调。

技术栈：Python、PyTorch、Transformers、PEFT（LoRA / QLoRA）、LLaMA-Factory、DeepSpeed、vLLM、AutoAWQ、DeepSeek-V3（数据生成与评审）

个人职责：
1. 构建约 8,000 条 SFT 数据：来源覆盖脱敏工单问答、解决方案沉淀、产品手册与 FAQ、DBA 故障分析及线上 Bad Case，文档类用“大模型生成 + 人工抽检”构造，覆盖参数、错误码、SQL 调优、操作步骤、拒答五类并混入通用指令防遗忘；清洗流水线含 MinHash 去重、长度格式过滤、脱敏、DeepSeek-V3 质量打分剔除低质样本，固定切分并以 ShareGPT 格式版本化管理。
2. LoRA / QLoRA 训练：基于 LLaMA-Factory + PEFT 对 Qwen2.5-7B-Instruct 做 LoRA 微调，完成 r 与 epoch 消融，训练推理模板一致、prompt 段不计 loss；验证 QLoRA（NF4 双重量化）路径，显存由约 40G 降至 12G 内、精度损失 <1pp，形成 80G 卡 LoRA、24G 卡 QLoRA 两套方案。
3. SFT 后 DPO：由评审分数构造约 1,000 对偏好数据并补安全负例，针对拒答与高危命令拦截行为调优，不额外训练奖励模型。
4. 评估与部署：300 条分层评测集从准确率 / 幻觉率 / 拒答率 / 格式合规四维评估，LLM 评审 + 10% 人工校准，基座 / 微调 / ±RAG 四组 A/B，C-Eval、CMMLU 子集回归；合并权重后 AWQ INT4 量化，vLLM 部署并开启前缀缓存，灰度后作为内部默认模型发布，Bad Case 回流。

项目成果：
1. **领域效果**（300 条分层评测集）：准确率 61% → 84%，幻觉率 23% → 7%，正确拒答率 48% → 91%（DPO 后 96%），格式合规 97%；微调 + RAG 较基座 + RAG 再提升 11pp。
2. **通用能力回归**：C-Eval / CMMLU 子集下降 <1.5pp，遗忘可控；高危命令零直接输出。
3. **部署资源**：AWQ INT4 后显存 15G → 5.5G，前缀缓存 TTFT 降约 40%，vLLM 吞吐较原生推理提升约 2.3 倍，支撑单张消费级显卡部署。

项目四：运维知识库 RAG（2024年07月 - 2025年06月）

项目背景：

在 OCP 内构建 AI 助手，整合大模型与 PowerRAG，融合内置知识库与数据库原生向量、全文索引，面向配置调优、故障诊断、性能分析。两个版本：交付版随 OCP 私有化交付到客户内网闭环运行；内部版复用同一份知识包与切分规则，用 Python 重建轻量检索服务，接入历史工单知识源，脱离产品发版周期快速迭代，并作为工单 Agent 的检索工具。

技术栈：交付版 Java、Spring Boot、Spring AI；内部版 Python、FastAPI、LangChain / LangGraph；OceanBase 向量索引 + 全文索引、BGE-M3 / 通义 Embedding、BGE-Reranker、多厂商模型可配置、Function Calling、SSE、Redis、MCP

个人职责：

1. 设计知识入库流水线：Markdown 解析，标题层级感知 + 父子分块（子块检索、父块生成），参数表与 SQL 示例整块保留，附版本与模块元数据，按内容哈希增量更新去重。
2. 设计基于 OceanBase 的向量存储：分块、元数据、向量同表，HNSW + 全文索引，一条 SQL 完成相似度、关键词与元数据过滤，私有化少一个组件；嵌入模型切换双表重建不中断。
3. 实现多路召回与重排：稠密 + BM25 并行、RRF 融合、Reranker 精排；错误码、参数名走精确通道，口语化提问 Multi-Query 改写；对比单路 / 混合 / 混合 + 重排确定默认配置。
4. 实现多轮检索与对话管理：意图分类、多轮历史压缩为独立检索问题、证据不足自反思二次检索、会话摘要压缩；注册只读 Function Calling 工具（集群版本、租户参数、告警、慢 SQL）让回答结合实时状态，不支持工具的模型自动降级纯 RAG。
5. 实现统一模型网关与可配置模型：适配 OpenAI 兼容、通义、豆包、DeepSeek、自建 vLLM，支持连接厂商、添加模型、设置系统模型（LLM + 嵌入 + Rerank）与连通性测试，评测集横向对比选型，统一超时重试降级，SSE 流式输出。
6. 建立防幻觉与评测闭环：仅基于证据作答并附章节锚点，低相关度拒答并引导提工单；300 条评测集跟踪 Recall@5 / MRR / 忠实度 / 引用正确率，Bad Case 归因到切分、召回、重排或提示词逐轮迭代；内部实例接工单库并将检索封装为 REST / MCP 供 Agent 复用。

项目成果：

1. **交付规模**：交付版知识库约 1 万篇文档、500MB 知识包、10 万 + 分块，随 OCP 版本发布。
2. **检索与回答质量**（300 条评测集）：Recall@5 由单路向量 68% 提升至 89%，MRR 0.81；忠实度 94%，引用正确率 97%；流式首字 P50 0.8s，端到端 P95 3.5s。
3. **使用效果**：内部值班常见问题自助解决率约 60%，检索能力复用于工单 Agent。

教育经历

湖北第二师范学院　2018年09月 - 2022年06月

计算机科学与技术 本科